

# Reporte de Proyecto: Detección de Cáncer de Cabeza y Cuello mediante Radiómica y Deep Learning

## 1. RESUMEN

El presente trabajo aborda el desafío de la detección de cáncer de cabeza y cuello, una patología con más de 20,000 casos estimados por año en EE. UU.. El problema principal identificado es la falta de entendimiento común entre clínicos y científicos de datos, lo que obstaculiza la investigación en radiómica y el uso de biomarcadores de imagen para el pronóstico.

La propuesta consiste en un caso de estudio, una arquitectura y un método de Deep Learning (Aprendizaje Profundo) diseñado para el procesamiento y análisis de imágenes tomográficas PET (Tomografía por Emisión de Positrones).

Para la validación se utilizó un dataset público de radiómica. La eficacia del método se evaluó utilizando medidas de calidad estándar: Exactitud (Accuracy), Precisión, Sensibilidad (Recall) y F1-Score.

Como trabajo futuro, se plantea explorar un enfoque híbrido que integre inteligencia artificial deductiva apoyada en el modelado de conocimiento experto, así como la incorporación de técnicas modernas como aprendizaje por refuerzo y métodos de ensamble.

## 2. MÉTODO PROPUESTO

La arquitectura propuesta para la ciencia de datos consta de tres fases principales:

1. **Preparación de la imagen:** Procesamiento inicial de los datos.
2. **Análisis de imagen (Deep Learning):** Uso de redes neuronales convolucionales (CNN) para reducción de dimensionalidad y extracción de características, y redes neuronales recurrentes (RNN) para el aprendizaje de imágenes seriales.
3. **Optimización:** Ajuste de hiperparámetros y evaluación.

Algoritmos y Pasos Relevantes

Los algoritmos se detallan por fases:

- **Fase 1 - Preparación de la imagen:**

1. **Selección distribuida de N frames:** Selección de cuadros para cada serie de imágenes del paciente.
  2. **Conversión a float:** Para evitar desbordamiento de datos.
  3. **Reescalado:** Ajuste de la escala de grises entre 0-255.
  4. **Conversión a uint8:** Transformación a entero sin signo.
  5. **Interpolación:** Redimensionamiento para asegurar dimensiones uniformes en todos los frames.
  6. **Construcción de datos:** Creación del dataset de imágenes para el análisis.
- **Fase 2 - Análisis de imagen con Deep Learning:**
    1. **CNN:** Capas de convolución y pooling para extraer características y reducir dimensionalidad.
    2. **Time Distributed (TD):** Transformación de la estructura original en una secuencia de N frames (imagen serial).
    3. **RNN:** Red neuronal recurrente (GRU o LSTM) que aprende de la serie de imágenes para clasificar y predecir.
  - **Fase 3 - Optimización de hiperparámetros y evaluación:**

Se evalúa el desempeño variando parámetros clave como la selección de N (número de frames), parámetros de compilación (épocas, batch size, optimizador), densidad de capas/kernels y la tasa de Dropout.

### **3. DISEÑO DE EXPERIMENTOS**

El diseño experimental se divide en las características del conjunto de datos y los parámetros de configuración del modelo.

#### **1) Características del dataset**

Se utilizó el dataset "18F-FDG PET Radiomics Head and Neck Cancer".

<b>Dataset</b>	<b>Número de muestras (Imágenes PET seriales)</b>	<b>Dimensiones de cada frame</b>	<b>Clases</b>
Head and Neck Cancer	124	128x128	Presencia o ausencia de tumor maligno

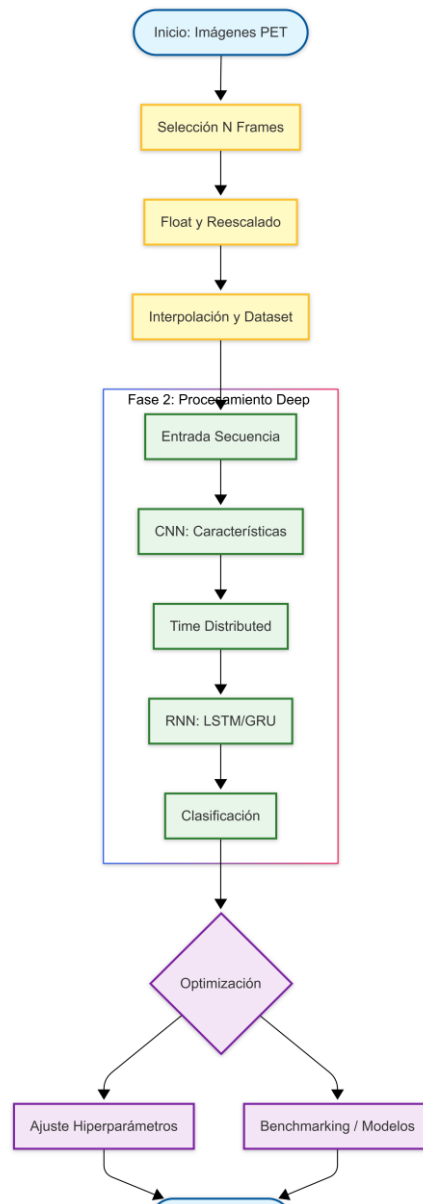
## 2) Parámetros de optimización

Se exploraron diversas configuraciones para encontrar el modelo óptimo:

- **Compilación:**
  - Épocas: 10, 20, 30, 40, 50.
  - Batch size: 10, 20, 30, 40.
  - Optimizadores: AdaGrad, Adadelta, RMSprop, Adam.
  - Funciones de activación: Linear, Sigmoid, Tanh, ReLU.
- **Arquitectura (CNN-TD-RNN):**
  - Capas CNN: 1 a 4 niveles (filtros 16 a 512).
  - RNN: GRU y LSTM con unidades de 16 a 512.
  - Dropout: 0, 0.1, 0.25, 0.5.
  - Capa densa: 16 a 1024 neuronas.

También se comparó con técnicas de Transfer Learning (MobileNet, VGG16, ResNet50, etc.) y algoritmos clásicos como Random Forest, SVM y KNN.

#### 4. DIAGRAMA DE FLUJO



#### 5. RESULTADOS Y DISCUSIÓN

Siguiendo el método propuesto, se obtuvieron los siguientes resultados destacados:

1. **Selección de Frames (N):** El análisis mostró que un número de frames (N) entre 10 y 20 optimiza las medidas de calidad, alcanzando valores cercanos a 1.0 en Accuracy, Recall y Precision.

2. **Matriz de Confusión:** En las pruebas con N=10 sobre un conjunto de 25 pacientes, el modelo clasificó correctamente 4 casos de ausencia y 21 de presencia de tumor, sin cometer errores (0 falsos positivos/negativos).
3. **Comparación de Métodos:** El método propuesto (CNN-TD-RNN) superó a otras arquitecturas y algoritmos clásicos.

**Tabla de Comparación de Resultados:**

Método	Accuracy	Precision	Recall	F1-Score
<b>Método Propuesto (CNN-TD-RNN)</b>	<b>1.0</b>	<b>1.0</b>	<b>1.0</b>	<b>1.0</b>
VGG16 / ResNet50 / Xception	0.96	0.9545	1.0	0.9767
SVM	0.96	0.9545	1.0	0.9767
MobileNet / KNN	0.72	0.9474	0.75	0.8372

Estos resultados indican que la arquitectura propuesta logra una clasificación perfecta en el conjunto de prueba, superando la generalización de modelos pre-entrenados complejos.

## 6. CONCLUSIONES

- La detección de cáncer es un gran desafío que depende de múltiples factores, y la colaboración interdisciplinaria es vital para superar obstáculos en la investigación radiómica.
- Se presentó exitosamente un caso de estudio y un método de Deep Learning para procesar imágenes tomográficas PET, validado con un dataset público y medidas estándar.
- Se proporcionaron notebooks para garantizar la reproducibilidad de los experimentos.

- Como trabajo futuro, se considera la articulación con instituciones médicas para la recolección de nuevas imágenes y la exploración de enfoques híbridos de IA que combinen modelos inductivos con razonamiento deductivo y conocimiento experto.

## **REFERENCIAS**

- Fuller, Clifton, Hesham Elhalawani, and Abdallah Mohamed. “MICCAI 2018 – Computational Precision Medicine Challenge: 18F-FDG PET Radiomics Risk Stratifiers in Head and Neck Cancer”. 29 July 2021. Web. 10 Dec. (2022). DOI: <https://doi.org/10.6084/m9.figshare.15075195.v2>.